



소비가한 OCR 파이프라인 아키텍처 구조도

제 3 회 ITDA 연합학술제 1 차 예선 · 아키텍처 구조도·설계 요약서

팀 [CODE]_서브웨이

환경 4-Core vCPU · GPU 없음 · 오프라인

일자 2026. 9. 15

01

전체 파이프라인 아키텍처

탐지·인식은 사전학습 모델이, 날짜 선택은 직접 정의한 규칙이 담당한다. 판독에 실패한 사진에만 조건부 폴백(표 1)이 추가로 동작한다.

①	입력 · 전처리 EXIF 회전 보정 → 긴 변 640px 축소본으로 시작, 후보가 없을 때만 1,024px 재시도 해상도를 더 올려도 정확도 $\pm 1\%$ p, 시간은 +30~50% 증가하여 기각
	텍스트 탐지 · 사전학습 딥러닝 모델 장당 1 회, 640px 축소본에서 위치만 탐지 (약 0.3 초) 검출 비용은 픽셀 수에 비례 · 초기 CRAFT 는 500 장 2,905 초로 한도 초과, 교체 후 1.8 초/장
②	텍스트 인식 · 사전학습 딥러닝 모델 글자 순서로 8 개씩 배치 인식 · 연도 포함 날짜를 찾으면 잔글씨는 생략 날짜는 포장에서 가장 큰 글자이므로 영양성분표의 수십 개 박스 인식을 생략하여 속도 확보
	2 패스 다수결 후보가 검출된 줄만 원본·1,024px 로 재인식하여 3 표 다수결 20→2, 18→1e 같은 한 자릿수 오독 보정 · 측정 500 장 77.0 → 78.4%, 퇴보 0
③	규칙 후처리·선택 오독 복원 → 신뢰 등급(완전 날짜 > 압축 > 연월 > 월일) → 같은 등급 안에서 가장 늦은 날짜 9 자리 이상 숫자열(품목보고번호·바코드) 제거 · 연도 2017~2031 · 라벨링 도구와 같은 규칙 정본 · 규칙마다 500 장에서 퇴보 없음을 확인한 뒤 채택
	출력 YYYY-MM-DD · 연도나 일이 없으면 그 칸만 NONE · 후보 0 개면 NONE 추정값은 출력하지 않음 · NONE 도 정답 값(전수 라벨의 약 5~7%)

● 사전학습 딥러닝 모델 ● 규칙 · 재인식 단계

그림 1 — 전체 파이프라인 구조

장치	발동 조건	동작
도트매트릭스 폴백	탐지·인식 후 후보 없음 (약 15%)	점 글자를 이어 붙인 뒤(침식 → 블러 → 팽창) 원본 해상도로 재탐지·재인식 미검출 사진의 육안 분석에서 도트 인쇄가 다수임을 확인하고 도출
파인튜닝 인식기 폴백	규칙 적용 후에도 NONE (약 6%)	팀 라벨의 날짜 크롭 393 장으로 파인튜닝한 인식기로 탐지·규칙 단계 재수행(+0.2 초/장)
시간 예산 가드	예산 소요 2,000 초 초과	최근 20 장 속도로 총 소요를 예측해 폴백 생략 → 2 패스 생략 → 남은 장 NONE 순으로 경량화 시간 초과를 구조적으로 차단

표 1 — 조건부 폴백과 가드

1.1 검증 방식과 자체 테스트

라벨링 · 측정 분리	배포 3,352 장 전수를 팀이 직접 라벨링(포장 원문 그대로 기록, 규칙 정본으로 정규화) · 측정 전용 500 장은 튜닝·학습에 사용하지 않아 모든 수치는 미학습 데이터 기준
채택 기준	500 장에서 회복·퇴보를 따로 세어 퇴보 0 인 변경만 채택 · $\pm 1\%$ p 는 잡음으로 간주 · 결정에 쓰지 않은 별도 블록 470 장도 같은 폭(+8.8%p) 상승하여 과적합 없음
자체 테스트 · 재현성	500 장 완전일치 84.2% (필드평균 88.8%) · 4 코어 CPU 2.2 초/장, 500 장 약 1,100 초 (한도의 45%) · 모델 21 MB, 외부 API 없음 · 버전 고정 + 인터넷 차단 Run All 완주 확인

표 2 — 검증 방식과 자체 테스트 결과

1.2 단계별 성능 이력

단계 (누적)	정확도 (500 장)	속도 (초/장)	변경 내용
초기 (EasyOCR)	39.1% (133 장)	5.8	미검출이 오답의 대다수
탐지·인식 모델 교체 (PP-OCRRv5 mobile)	71.2%	1.80	속도 한도 초과로 교체
+ 신뢰 등급 선택 · 도트매트릭스 폴백	77.0%	2.90	잡음 숫자열 오답 제거 · 도트 인쇄 미검출 회복
+ 2 패스 다수결 · 후처리 규칙 보강	81.8%	1.94	한 자릿수 오독 · 일(日) 누락 보정
+ 파인튜닝 인식기 폴백 (최종)	84.2%	2.2	미인식 사진만 재시도 · 필드평균 88.8%

표 3 — 단계별 성능 이력 · 측정 전용 500 장 기준 · 라벨 1,303 장 전체 81.2% (파인튜닝 폴백 적용 전 측정)

02 | 설계 논리

속도 한도로 설계를 결정 : 초기 CRAFT+EasyOCR 은 500 장 2,905 초로 한도(4 코어 CPU-2,400 초)를 초과하여 PP-OCRv5 mobile 로 교체, 1.8 초/장으로 한도 내 진입(정확도는 표 3).

탐지는 저해상도, 인식은 원본 해상도 : 검출 비용은 픽셀 수, 인식 비용은 박스 수에 비례. 날짜는 포장에서 가장 큰 글자여서 640px 에서도 검출되므로, 인식만 원본 해상도로 수행.

규칙의 근거는 라벨 분포 : “가장 늦은 날짜” 규칙만으로는 영양성분표 숫자열이 실제 날짜를 대체(500 장 중 15 장)하므로 신뢰 등급 안에서만 늦은 날짜를 선택. 모호한 형식의 해석은 팀이 직접 라벨링한 3,352 장 전수 통계로 결정(표 4).

파인튜닝은 폴백으로만 사용 : 라벨 크롭 393 장 학습 인식기를 1 순위로 두면 기존 정답이 퇴보하므로, 사전학습 인식기가 NONE 을 낸 사진에만 적용하여 퇴보 없이 개선.

모호한 경우	해석 규칙 (파서 · 라벨링 도구 공통)	근거 (전수 라벨 3,352 장)
연도 위치 불분명	4 자리 연도가 앞이면 년/월/일, 뒤면 일/월/년. 구분자 종류는 무관	연도 앞 2,217 장 · 연도 뒤 362 장
연·월·일 순서 불분명 (2 자리 연도)	년/월/일 우선 → 연도가 허용 범위(2017~2031) 밖이거나 2028 년 이후면 일/월/년 → 년/월/일 344 장 : 일/월/년 102 장 같은 사진에 BEST BEFORE-EXP 등 영문 단서가 있으면 일/월/년	
공백 구분·영문 월	공백 구분은 일/월/년 우선 (유럽식 각인) · 영문 월은 월로 확정, 4 자리는 연도, 1~2 자리는 일	전부 수입품 · 영문 월 148 장
날짜 복수 표기	신뢰 등급이 같은 후보 중 가장 늦은 날짜 (소비기한 ≥ 유통기한 ≥ 제조일)	복수 표기 345 장(10.3%)

표 4 — 날짜 해석 규칙 · 모호한 표기는 이 표의 해석으로 채점(운영진 확정)

03 | 제한된 CPU 환경에서의 속도·오탐 최적화

3.1 속도

추가 비용은 어려운 사진에만 : 1,024px 재시도·도트·2 패스·파인튜닝 폴백은 조건부, 대다수는 640px 1 회 종료. 시간 예산 가드로 완주 보장.

잔글씨 조기 종료 + 8 개 배치 인식 : 인식 시간 35% 절감. 480px 경량화는 효과 없어 기각.

3.2 오탐

품목보고번호 오탐 차단 : 20130628332176 의 앞 8 자리가 완전한 날짜 형식이므로 9 자리 이상 숫자열은 통째로 제거, 바코드도 차단.

영양성분표·중량 차단 : 연.월은 월이 2 자리일 때만, 공백 구분 날짜는 숫자 토큰 6 개 이하일 때만 인정. 탐지 임계값 완화는 -12 장으로 기각.

04 | 추후 활용 방안 및 확장성

탐지·인식·폴백 구조는 식품 소비기한에 한정되지 않고 “제품에 표기된 기한” 전반에 적용되므로, 식품 내 인접 접점과 규칙 계층만 바꾸면 되는 타 산업을 선별하였다. 푸드 QR 은 제조사 수천 곳이 도입해야 하나 OCR 은 읽는 쪽 한 곳에서 미부착 상품까지 다룬다.

활용 도메인	선정 이유 (법적 근거)	본 파이프라인과의 접점
온라인 식품 발송 시점 소비기한 검증	공정위 고시(2023)로 “발송일 기준 N 일 이상” 표기 의무. 이행 여부를 확인할 수단이 없음	대회 데이터와 동일 분포. 포장 시 뒷면을 촬영하여 표기 약속과 대조하고, 미달 시 발송을 차단
단체급식 식재료 검수일지 자동화	검수일지에 식재료 소비기한 기록이 규정상 의무. 영양(교)사가 매일 수기 작성	납품 검수 시 촬영으로 검수일지 자동 기입, 기준 미달 식재료 반려
고압가스 용기(LPG·산소) 재검사기한 각인	재검사 미필 용기는 유통 불가. 기존 재고는 QR 없이 곡면 금속 각인에만 의존	곡면 각인은 저대비 도트 글자로 도트매트릭스 폴백과 동일한 문제. 충전소 입고 시 재검사 시급도 순 자동 분류
소화기 내용연수·압력점검	내용연수 10 년 법정. 관리업체가 전국 순회 점검	제조연월 라벨 촬영으로 폐기 대상 자동 분류. 연·월 형식은 현 규격으로 지원

표 5 — 도메인 확장 후보 · 법적 강제력과 규모를 기준으로 선별한 식품 도메인 2 건·타 산업 2 건

4.1 운영 원칙

교차확인 레이어 : OCR 결과는 안전 인증이 아닌 교차확인 신호로 사용한다. 기존 법정 점검 제도 위에서 이력 DB 와 대조하여 기한 도래분을 탐지하고, 불일치 건은 예외 처리한다.

비대칭 실패 설계 (Recall > Precision) : 오탐은 재확인 비용에 그치나 미탐은 치명적이므로 모호한 건은 “확인 필요”로 분류한다. 대회 제출본의 NONE 정책(답한 사진의 정밀도 86%)과 동일하며, 신뢰 임계값 하나로 조절한다.

데이터 플라이휠 : 사람이 확정된 “확인 필요” 건을 라벨로 축적하여 파인튜닝에 순환시킨다.

05 | 남은 과제

단일 날짜의 의미 판별 : 현재는 단일 날짜를 소비기한으로 채택하나, 제조·포장일자만 표기된 사진의 정답은 NONE 이다. 영문 인식기는 “제조” · “까지” 등 한글 단서를 읽지 못하므로, 후보가 하나뿐인 사진은 주변 박스를 한글 인식기로 재인식하여 제조·포장 여부를 판별한다.

미국식(월/일/년)·영국식(일/월/년) 구분 : 가운데 숫자가 13 이상이라 일/월/년으로 읽을 수 없을 때만 월/일/년으로 해석한다(등급 2). 양쪽 다 가능한 표기는 전수 라벨에서 유럽식 448건 대 미국식 2건이라 일/월/년을 유지한다(측정 500장 변화 0). 남은 과제는 원산지·단위(oz · lb) 등 제품 문맥 단서로 구별하는 것이다.

시각이 붙은 단일 날짜의 처리 : 10.14 09:45 처럼 시각이 동반된 날짜는 제조일로 간주하는 것이 일반적이나, 라벨 검토 과정에서 소비기한에도 시각이 붙는 사례가 확인되었다. 시각 유무만이 아닌 한글 단서·날짜 순서와 결합하여 판별한다.