


맞히는 OCR에서, 믿을 수 있는 OCR로

소비기한 추출 파이프라인과 중고거래 게시글 적용

4코어 CPU · GPU 없음 · 오프라인 환경에서의 경량 OCR 설계와 검증

문제 정의

무엇을, 어떤 제약 아래에서 풀었는가



출발점 : 제약이 설계를 결정했습니다

3,352장

정답 라벨 없음

상품 뒷면 사진만 제공
정확도를 잴 기준부터
직접 만들어야 했습니다.

4코어 CPU

GPU 없음 · 오프라인

채점 서버 Ubuntu 22.04, RAM 8GB
무거운 모델·외부 API 사용 불가

2,500초

500장 제한 시간

초과하면 결과 파일이 나오지 않아
정확도까지 0점. 장당 5초가 상한.

EasyOCR 탐지기를 쓴 초기 구성은 4코어에서 **장당 5.8초, 500장 2,905초** 로 한도를 넘겼습니다.

정확도를 올리기 전에 **"끝까지 돌아가는가"**부터 풀어야 하는 문제였습니다.

그래서 모든 설계 결정에 **정확도와 시간을 함께** 기록했습니다.

데이터와 검증 설계

정답이 없는 데이터에서 정확도를 재는 법



검증 설계 : 규칙을 먼저 정하고, 시험지를 봉인했습니다

01 해석 규칙을 먼저 문서로 확정

- 라벨러는 포장에 찍힌 그대로만 입력
- 해석(연·월·일 순서, 2자리 연도)은 도구가 규칙으로 처리
→ 라벨과 모델이 동일한 규칙 공유

02 3,352장 전수 직접 라벨링

- 5명 분담, 자체 제작 라벨링 도구 활용
- 오답 446장을 사람이 다시 보고 라벨 오류 수정

03 약점 유형만 골라 추가 촬영

- 도트 인쇄·각인·두 날짜 병기 위주의 389장 추가 촬영 및 라벨링
- 한 번도 본 적 없는 시험지로 사용

데이터 분리

500

2,852

봉인 500장 학습·규칙 도출에 쓰지 않고 측정 전용으로 사용
판정용 2,852장 모든 채택·기각 판정

채택 기준

- 새로 맞힌 장(회복)과 새로 틀린 장(퇴보)을 각각 산정
- 퇴보가 회복의 1/3을 넘으면 점수가 올라도 기각
- $\pm 1\%p$ 는 잡음으로 보고 근거로 사용하지 않음


정답 라벨도 검증 대상 : 고친 라벨 16장 중 **11장은 모델이 맞은 쪽** 이었습니다.

| 아키텍처 설계

왜 이 구조인가

3

전체 파이프라인 : 쉬운 사진은 한 번에, 어려운 사진에만 비용을



■ 사전학습 딥러닝 모델 ■ 규칙·재인식 단계

조건이 맞을 때만 동작하는 단계

장치	발동 조건	동작	효과 (회복 / 퇴보)
이웃 줄 재탐지	후보 줄 옆에 크기 비슷한 숫자 줄	그 주변만 원본 해상도로 다시 탐지	병기 +5 / -1
도트 인쇄 폴백(대체 경로)	후보 없음	점을 이어 붙이는 전처리 후 재시도	+17 / -0
파인튜닝 인식기	그래도 후보 없음	우리 라벨로 학습한 인식기로 재시도	+7 / -0
시간 예산 가드	예상 소요 2,000초 초과	폴백 생략 → 2패스 생략 → NONE	완주 보장

※ 위 세 수치는 각각 따로 측정한 개별 효과이며 단순 합산이 아님.

딥러닝은 “**읽기**” 만, 소비기한을 고르는 판단은 **설명 가능한 규칙** 이 맞습니다.

설계 사고 : 오답을 “정답이 사라진 단계” 로 진단했습니다

예선 구성의 전체 오답 **603장** (봉인 500장 포함, 예선 시점 진단) 마다 정답 날씨가 파이프라인 어느 단계까지 살아 있었는지 추적

183

못 읽음

탐지 실패 · 전부 미인식

원본 재탐지
작은 사진 확대
파인튜닝 풀백

290

잘못 읽음

인식기가 숫자를 오독

후처리 규칙 보강

111

읽었다가 지움

다시 읽기가 정답을 덮어씀

교정만, 삭제 금지
유지 규칙

19

잘못 고름

가짜 후보가 늦은 날짜로 승리

이중 해석 억제

단계마다 처방이 다릅니다

- “읽었다가 지운 경우” 모델이 아닌 코드 로직의 문제 → 1차 후보를 지우지 못하도록 처리 (+53 / -5)
- “못 읽은 경우” 해상도를 올려도 회복되지 않음 (5가지 구성 전부 $\pm 1\%p$, 시간만 +30~50%) → 원인은 탐지가 아니라 인식 품질

오답을 뭉뚱그려 “모델을 키우자” 가 아니라, **원인별로 가장 가벼운 처방** 을 골랐습니다.

후처리 규칙 : 소비기한을 다른 숫자와 구분하는 법

구분 대상	실제 예	규칙	근거
품목보고번호 · 바코드	20130628332176	9자리 이상 숫자열은 통째로 제거	앞 8자리가 완전한 날짜 형식
영양성분표 · 중량	78 7 5 31 / 30.4 GRAMS	신뢰 등급 : 완전 날짜 > 공백·압축 > 연월 > 월일	잡음이 이긴 오답 15장에서 도출
제조일자 · 유통기한	25.06.26 / 26.06.25	가장 좋은 등급 안에서 가장 늦은 날짜	소비기한 ≥ 유통기한 ≥ 제조일
시각 · 로트번호	13:11 / A03 / L8	날짜 패턴에서 제외, 옆 글자를 '일' 자리로 읽지 않음	도트 인쇄 제품에 혼함
연·월·일 순서	30.07.26 / 24/12/21	년월일 우선. 무효·2028년 이후면 일월년	라벨 : 년월일 344 · 일월년 102
범위 밖 연도	2033, 2009	2017 ~ 2031 만 인정	전수 라벨 최소 2017

미인식(NONE) 기준

후보가 하나도 없으면 추측하지 않습니다.
연도나 일만 없으면 그 칸만 NONE (NONE-10-14, 2027-07-NONE)

라벨과 모델이 같은 규칙

운영진 확정 : 모호한 표기는 팀이 문서화한 규칙으로 채점,
규칙 문서 하나를 라벨링 도구와 파서(parser)가 공유


규칙마다 어떤 오답에서 나왔는지 와 회복·퇴보 수 가 기록되어 있습니다.

성능과 속도 검증

무엇을 채택하고 무엇을 버렸는가



정확도 : 봉인 500장 86.2%, 필드 평균 90.8%



※ 앞 세 단계는 개발용 133장, 이후는 500장 기준

※ 11번 차트의 71.2%는 본선 측정셋(500장) 기준, 12번 표의 67.7%는 같은 변경을 초기 라벨 133장으로 다시 랜 값

봉인 500장 · 완전일치

86.2%

예선 제출본 84.2% → +2.0%p

구분	정확도
필드 평균 (채점 방식)	90.8%
작은 사진 (≤700px)	83.7%
중간	89.5%
큰 사진	86.7%
두 날짜 병기	78.4%
미인식률	3.0%

판정용 2,852장에서도 **82.3 → 86.7%** : 튜닝에 쓴 셋과 봉인 셋이 함께 올랐습니다.

모델·대안 비교 : 점수가 올라도 기각한 것들

시도	결과 (회복 / 퇴보)	판단	이유
탐지·인식기 PP-OCRv5 mobile 로 교체	39.1 → 67.7%, 5.8 → 1.8초	채택	속도 한도와 정확도를 동시에 해결
다시 읽기 규칙 (1차 후보를 지우지 못하게 등)	+63 / -5	채택	82.3 → 84.3%. 코드 로직 결함 수정
해석 규칙 4개	+39 / -2	채택	병기 64.9 → 78.3%
주변 재탐지 · 확대 재시도 · 파인튜닝 재시도	+25 / -1	채택	못 읽은 사진에만 비용을 투자
파인튜닝 인식기를 다시 읽기에 적용	+86 / -64	기각	점수가 올라도 맞던 답을 틀리게 만들면 버림
합성 도트 글자 3,000장 추가 학습	정밀도 84 → 81%	기각	진짜 글씨를 대충 읽게 됨
인식기 셋 다수결	+8 / -4, 장당 +0.43초	기각	퇴보가 회복의 1/3 초과
탐지 해상도 상향	±1%p, 시간 +30~50%	기각	원인이 해상도가 아님
한국어 인식기로 한 번 더 읽기	판정용 +7 / -2, 장당 +0.3~0.7초	기본 꿈	시간이 한도의 94% 까지 차서 여유를 택함

파인튜닝은 점수를 올렸지만 **퇴보 64장** 때문에 버렸습니다. 점수보다 회복과 퇴보로 판단했습니다.

속도·효율 : 한도의 55 ~ 79%, 그리고 완주 보장

2.7 ~ 4.0초

장당 처리 시간

개발 PC 두 대, 4스레드

1,370 ~ 1,985초

500장

한도 2,500초의 55 ~ 79%

2.0GB

최대 메모리

한도 8GB (새 환경 500장 실측)

0원

학습 비용

무료 Colab T4 만 사용

속도를 만든 결정

- 탐지는 640px 축소본에서 장당 1회 (탐지 비용 = 픽셀 수)
- 인식은 큰 글자부터, 낱파를 찾으면 잔글씨 생략
- 사진의 88% 는 1.8초에 끝나고, 재시도까지 간 12% 가 시간의 절반을 씁니다
- 다시 읽기는 후보 줄 크롭만, 풀백은 후보 없는 장에만

시간 예산 가드 : 3단계 자동 경량화

최근 20장 속도로 총 소요를 예측, 2,000초를 넘길 것 같으면

- 1 재시도 단계 생략
- 2 다시 읽기 생략
- 3 남은 장 NONE, 결과 파일은 반드시 생성

채점 서버 속도를 모르는 상황에서 **"느리면 0점"** 을 구조로 막았습니다.

실행 화면 : 실제 파이프라인 출력




final_date
2026-07-02

날짜 후보 (패턴 · 경로 · 신뢰도)
2026-07-02 YYYY · p2 · 0.98

처리 2.97초 (CPU 4스레드)
일반 인쇄 · 1패스 후보 → 2패스 다수결로 확정

일반 인쇄




final_date
2026-06-25

날짜 후보 (패턴 · 경로 · 신뢰도)
2025-06-26 YY · p2 · 0.78
2026-06-25 YY · p2 · 0.78

처리 4.73초 (CPU 4스레드)
제조·소비 병기 · 두 후보 중 늦은 날짜(소비기한) 선택

제조·소비 병기



final_date
2026-01-21

날짜 후보 (패턴 · 경로 · 신뢰도)
2026-01-21 CMP · erode2/p1@1024 · 0.89

처리 12.67초 (CPU 4스레드)
도트 인쇄 · 기본 인식 실패 → 점 잇기 전처리 후 재시도로 회수

도트 인쇄 (폴백)



final_date
NONE

날짜 후보 (패턴 · 경로 · 신뢰도)
후보 없음 → 추측하지 않고 미인식으로 출력

처리 21.32초 (CPU 4스레드)
확신 없음 → 미인식(NONE) · 현장에서는 사람 확인 대기열로

미인식 → 판매자 입력

- 빨간 상자 = 선택된 날짜 줄, 회색 상자 = 다른 후보. 아래 패널은 파이프라인이 실제로 낸 값·후보·처리 시간
- 병기 사진 : 25.06.26(제조)과 26.06.25(소비)를 모두 읽고 늦은 날짜를 선택
- 네 번째 : 후보가 없으면 날짜를 지어내지 않고 NONE. 게시 화면에서는 빈칸으로 두고 판매자가 입력

재현 : 새 환경에서 설치 → 가중치 다운로드 → 봉인 500장 Run All 완주, 공식 측정과 500장 답이 모두 일치

도메인 적용과 운영

중고거래 식품 게시글의 잔여기한




적용 도메인 : 중고거래 식품·건강기능식품 게시글의 소비기한

소비기한은 판매자가 손으로 적습니다. 적발된 위반 375건 중 **211건이 사용기한 확인 불가·불일치**, 전담 모니터링 인력은 **5명**


아래는 시연용으로 만든 서비스 화면(설계안)이며 실제 앱을 구현한 것은 아닙니다. 사진·판독값·확신도는 파이프라인의 실제 출력입니다.




① 날짜면 촬영



② 모델이 확신하면 자동 입력



③ 모델 확신이 낮으면 빈칸



④ 날짜·남은 일수·원본

모델 결과별로 판매자에게 일어나는 일

모델 결과	판매자에게 일어나는 일
맞게 읽음	채워진 날짜를 확인
못 읽음 · 확신 낮음	빈칸. 손으로 입력 (지금과 같음)
이르게 읽음	확대본을 보고 고침
늦게 읽음	확대본을 보고 고침. 안 고치면 남은 날이 많게 표시

판매자가 실제로 확인하는 한, 정확도는 안전성이 아니라 **자동 입력 비율**을 정합니다. 속이려는 소수는 기존 사후 모니터링이 맡습니다.

포장 판독과 사진 기반 자동 입력은 이미 있습니다. 저희는 둘을 잇는 **빈자리**를 채웁니다.

운영 구조와 비용 : 건당 0.2 ~ 5.8원, 도입 이유는 규제 대응

항목	내용
1차 대상	건강기능식품 카테고리 (미개봉 · 소비기한 이내 · 연 10회 이하)
규모	게시글 월 약 2.4만 건, 하루 약 800건 (식약처 자료)
구조	플랫폼 서버에서 추론. 모델 21MB, CPU 전용, 10초 제한
서버	하루 53분 ~ 2.4시간 = 서버 1대의 4 ~ 10%
비용	게시글 한 건당 0.2 ~ 5.8원. 라이선스·GPU·학습비 0원

도입 이유 : 비용 절감이 아닙니다

- 위반 처리비 절감으로는 본전이 안 됩니다: 손익분기 780 ~ 1,900원, 사람 검토는 약 86원 (가정)
- 건강기능식품 개인 간 거래는 시범사업. 게시글마다 남는 사진과 판독 기록이 관리 체계의 증거
- 남은 일수 표시·자동 숨김은 날짜 칸만으로 되므로 OCR 효과로 세지 않았습니다.

자동 입력 기준 (직접 찍은 폰 사진 389장 실측) ※ 389장은 어려운 유형 위주라 보수적 추정치임

자동 입력 기준	채워지는 비율	채운 값의 정확도	틀린 값을 받는 판매자
기준 없음 (읽히면 채움)	70.2%	70.3%	20.8%
확신도 0.7 이상	44.7%	77.0%	10.3%
확신도 0.7 이상 + 10초 제한 (운영 기준)	40.6%	79.7%	8.2%
확신도 0.9 이상	16.5%	87.5%	2.1%

OCR 이 있어야 하는 것 : **입력값과 사진의 대조**, 날짜면이 찍혔는지 확인, 자동 입력과 수정값 추적

운영 아키텍처 : 서버는 지금, 온디바이스는 다음 단계

현재 — 서버 추론

- 판매자가 제목·가격을 쓰는 동안 서버가 사진을 읽습니다.
- 확신도가 0.7 이상이며 10초 안에 읽히면 칸을 채웁니다. 그게 아니라면 빈칸으로 남겨 둡니다.
- 모델이 21MB라 가볍습니다. GPU나 외부 API도 필요 없으며, 사진은 서버 밖으로 나가지 않습니다.
- 서버 한 대로 충분합니다. 지금 쓰는 양은 그중 4 ~ 10%뿐입니다.

다음 — 온디바이스 (폰 자체 추론)

- 폰 안에서 직접 돌리는 건 아직 해 보지 않았습니다.
- 모델 크기 상 구동은 가능할 것으로 보이나, 실측 전이므로 이는 추정에 그칩니다.
- 폰에서 장당 몇 초가 걸리는지, 배터리는 얼마나 쓰는지부터 재야 합니다.
- 실현 가능해진다면 서버 비용이 거의 사라지고, 사진도 폰 밖으로 나갈 필요가 없어집니다.

지금 돌아가는 건 서버 추론 하나뿐입니다. 온디바이스는 **가능성의 영역**입니다.

손실 절감과 ROI : 비용 절감으로는 손익분기에 못 미칩니다

OCR이 있어야 하는 것 / 낱자 칸만 있으면 되는 것

편익	누구에게	OCR 필요?	근거
입력값과 사진의 대조	구매자 · 플랫폼	예	판매자가 (모델 답을 보지 않고) 직접 입력한 값이, 모델이 숨겨둔 판독값과 우연히 같아 지나갈 확률 0.2 ~ 0.4%
낱자면이 찍혔는지 확인	구매자	예	메루카리는 소비기한 인쇄 사진을 필수로 요구합니다
입력 편의 · 판매자 수정값 축적	판매자 · 플랫폼	예	폰 사진 기준 자동 입력 41 ~ 45%
남은 일수 표시 · 기한 지난 글 자동 숨김	구매자 · 플랫폼	아니오	낱자 칸만 있으면 됨 — OCR 편익으로 세지 않음


손익분기 : 위반 처리비 절감만으로는 손익분기에 못 미칩니다

조건	연간 위반(가정 50% 포착)	연간 서버비	손익분기 1건당 처리비
20개월 평균, 기존 서버 여유분	435건	17만원	약 780원
거래조건 완화 뒤 추정, 기존 서버 여유분	180건	17만원	약 1,900원
거래조건 완화 뒤 추정, 전용 서버	180건	169만원	약 1만 9천원

사람이 30초 검토하면 약 86원. 손익분기 처리비는 이보다 **9 ~ 220배 큼니다**. 도입 이유는 비용 절감이 아니라 **규제 대응**입니다.

한계 : 어려운 유형 위주로 찍은 폰 사진에서는 다섯 장 중 한 장을 못 읽습니다

틀리는 방향 (직접 찍은 폰 사진 389장)



남은 한계

- 미인식 21.9% 는 봉인 500장(3.0%)의 약 일곱 배입니다. 찍은 사람과 촬영 조건에 따라 크게 갈립니다.
- 389장은 어려운 유형 위주로 찍은 것입니다. 실제 게시 사진으로 다시 측정해야 합니다.
- 조작·개봉 여부·카테고리를 바꿔 촬영을 피하는 것은 막지 못합니다.
- 판매자가 보지 않고 확인을 누르는 비율은 재지 못했습니다.

보완 계획

01

촬영 단계에서 막는다

촬영 안내와 해상도·흐림 검사
미달인 경우 재촬영

02

판매자 수정값으로 재학습

고친 값을 검수해 인식기 학습 데이터로

03

확인을 버튼이 아닌 직접 입력으로

버튼 대신 날짜의 '일' 칸을 다시 입력
실제 수정 비율을 지표로 활용

규칙으로 고칠 수 있는 오답은 거의 다 고쳤습니다. 남은 것은 **인식 품질(각인·도트)과 저해상도** 입니다.

확장성 : "제품에 찍힌 기한" 을 읽는 모든 곳

적용 분야	읽는 값	바꿀 것	그대로 쓰는 것
1단계 건강기능식품 → 2단계 가공식품 · 선물세트	소비기한	대상 카테고리, 상품별 촬영	파이프라인 전체
품목보고번호 인식 → 제품 조화·회수 확인	품목보고번호	9자리 숫자 마스킹 규칙 재설계	탐지 · 인식 (정확도 미측정)
식품공장 출하 전 날짜 인쇄 확인	소비기한	대조 대상 (제조일 + 품목별 일수)	농칠 확률 한 장당 0.2%
의약품 · 화학 제품 출하 표시물	제조번호 · 사용기한	표기 형식 규칙	읽기 · 대조 · 예외 처리

왜 옮겨 쓸 수 있는가

- 딥러닝 모델은 "글자를 읽는 일" 만 하고, 도메인 지식은 전부 규칙 문서 한 장에 있습니다.
- 읽기 → 기준값과 대조 → 예외만 사람에게 : 이 세 단계는 분야가 바뀌어도 같습니다.
- 사람(판매자·검수자)이 확정된 값이 다시 학습 데이터가 되는 순환 구조

규칙 문서만 바꾸면 되는 구조 : **모델을 다시 만들 필요가 없습니다**

정리

1

제약에서 출발

4코어 CPU · 2,500초 안에서 끝까지 돌아가는 구조. 봉인 500장 86.2%, 한도의 55 ~ 79%

2

검증을 먼저

전수 라벨링, 봉인 시험지, 회복·퇴보 기준. 점수가 올라도 퇴보가 크면 버렸습니다

3

틀리는 방식을 설계

확신이 없으면 NONE, 판매자가 직접 입력. 판매자 확인을 전제로, 정확도는 안전성이 아니라 자동 입력 비율이 됩니다.

부록 : 날짜 해석 규칙표 (모호한 표기)

상황	해석	근거 (전수 라벨 3,352장)
4자리 연도가 앞 / 뒤	앞이면 년/월/일, 뒤면 일/월/년. 구분자 종류는 무관	연도 앞 2,217 · 연도 뒤 362
2자리 세 개 (26.03.20)	년/월/일 우선. 무효이거나 연도 2028 이상이면 일/월/년	년월일 344 : 일월년 102
영문 유통 문구 (BBD, BEST BEFORE, EXP)	같은 사진에 있으면 일/월/년 우선	수입품 표기 관행
공백 구분 (30 12 23)	일/월/년	전부 수입품
영문 월 (04-Jul-21, 22OCT2021)	월 위치 확정, 4자리는 연도	148장
월/일/년 (06/18/23)	일/월/년이 불가능할 때만 (가운데 13 이상)	확정 미국식 2장
연월만 / 월일만	YYYY-MM-NONE / NONE-MM-DD	운영진 확정
날짜가 여럿	가장 좋은 등급 안에서 가장 늦은 날짜	병기 345장 (10.3%)

해석 기본값은 감이 아니라 **직접 단 라벨의 통계** 로 정했습니다.

부록 : 측정 수치 한눈에

측정셋	구성	완전일치	필드평균	비고
봉인 500장	예선 제출본 (9/13)	84.2%	88.8%	미인식 17
봉인 500장	본선 통합본 (9/28)	86.2%	90.8%	미인식 15, 정밀도 88.9%
판정용 2,852장	예선 구성 (지금 라벨로 채점)	82.3%		병기 64.9%
판정용 2,852장	본선 최종 (한국어 인식기 끄)	86.7%		병기 78.3% · 비병기 87.7%
직접 찍은 폰 사진 389장	본선 최종 (운영 수치 계산용)			미인식 21.9%, 자동 입력 41 ~ 45%

- 완전일치 : 연·월·일이 모두 맞은 사진 비율
- 필드평균 : 연·월·일을 따로 채점한 평균 (운영진 채점 방식)
- 회복 / 퇴보 : 이전 버전 대비 새로 맞힌 장 / 새로 틀린 장

모든 수치의 예측 파일과 실험 기록은 **저장소 results/ · docs/실험_기록.md** 에 있습니다.