

제3회 ITDA 연합학술제 본선 · 분석·설계 및 도메인 기획 보고서

맞히는 OCR에서, 믿을 수 있는 OCR로

4코어 CPU·오프라인 경량 OCR 파이프라인과
중고거래 식품·건강기능식품 게시글 적용

[CODE]_서브웨이

김민섭 · 박서현 · 이병철 · 이승아 · 조서영

2026. 10. 2

목차

1. 개괄

2. 데이터 구성 및 라벨링 전략

3. 아키텍처 설계 논리

4. 모델 선택 근거 및 성능 평가

5. 속도·비용 검증

6. 도메인 활용 및 운영 기획

7. 한계와 보완 계획

8. 추가 참고 자료 (선택)

1. 개괄

1-1. 핵심 접근 방식 요약

식품 포장 사진에서 소비기한을 읽는 문제를 **경량 사전학습 OCR + 날짜 해석 규칙 + 못 읽은 사진 전용 재시도**로 풀었다. 채점 조건(4코어 CPU, GPU 없음, 500장 2,500초, 인터넷 차단)이 설계를 정했다. 원칙은 하나다. **틀릴 때 안전하게 틀린다**. 확신이 없으면 날짜를 지어내지 않고 '미인식'으로 답한다. 풀어야 했던 문제와 대응, 측정값은 아래와 같다.

문제	대응	측정값	절
구매자는 적힌 날짜를 확인할 수 없다	판독 날짜와 날짜면 원본을 게시글에 표시	남은 날을 많게 읽는 오류 4.9% 를 따로 측정	6
판매자는 날짜를 손으로 옮겨 적는다	확신할 때만 칸을 채우고 판매자가 확인	폰 사진의 41 ~ 45% 자동 입력	6
포장에 날짜가 아닌 숫자가 많다	긴 숫자열 제거, 신뢰 등급	시험 문자열 26종	3-3
제조일과 소비기한이 함께 찍힌다	늦은 날짜 선택, 주변 재탐지	64.9 → 78.3%	3-3
도트 인쇄-각인-저해상도	못 읽은 사진에만 재시도	+17/-0	3-2
개발 데이터와 실제 폰 사진이 다르다	직접 찍은 389장으로 운영 수치를 따로 계산	미인식 3.0% 대 21.9%	4-3, 6-2
채점 서버 속도를 모른다	시간 예산 가드	한도의 55 ~ 79%	5
정답 라벨도 틀린다	오답 전수 재점검	오류 16장 중 11장은 모델이 맞음	2-2

1-2. 주요 결과 요약

항목	예선 제출본	본선 최종 구성
봉인 500장, 연·월·일 전부 일치	84.2%	86.2%
봉인 500장, 연·월·일 따로 채점	88.8%	90.8%
판정용 2,852장	82.3%	86.7%
제조일·소비기한 병기 (판정용 299장)	64.9%	78.3%
직접 찍은 폰 사진 389장 (운영 수치 계산용)	-	미인식 21.9%, 자동 입력 41 ~ 45%
CPU 속도 (4스레드)	장당 3.2초	장당 2.7 ~ 4.0초 (한도의 55 ~ 79%)
학습 비용	0원	0원 (무료 Colab T4)

판정용과 병기의 예선 값은 예선 규칙 구성(파인튜닝 재시도 제외)의 출력을 지금 라벨로 채점한 것이다.

도메인 기획 한 줄: 중고거래 플랫폼에서 판매자가 식품의 날짜면을 찍으면, 확신할 때만 소비기한 칸을 채우고 판매자가 확인한 날짜를 날짜면 원본과 함께 게시글에 표시한다. 못 읽으면 빈칸이고 틀리게 읽으면 판매자가 고친다. 판매자가 확인한다는 조건에서 정확도는 안전성이 아니라 **자동 입력 비율**을 정한다.

2. 데이터 구성 및 라벨링 전략

2-1. 사용 데이터

데이터	수량	용도
제공 데이터	3,352장	전부 직접 라벨링
└ 봉인 측정용	500장	최종 수치 전용. 본선의 규칙 도출·학습·채택 판정에 쓰지 않음 (예선의 채택 판정은 이 500장으로 했다)
└ 판정·학습용	2,852장	개선안 채택 판정. 인식기 학습용 글자 조각 1,439개 추출
직접 촬영 (추가 수집)	389장	팀원 4명이 보유 제품을 폰으로 촬영. 어려운 유형 위주. 학습에 쓰지 않고 시험지로 사용

제공 데이터는 저해상도(긴 변 700px 이하) 33%, 제조일·소비기한 병기 10% 이고 도트 인쇄와 각인이 많다. 이 세 무리가 오답의 대부분이다.

2-2. 라벨링 규칙 정의 및 수행 절차

규칙을 먼저 문서로 정하고, 라벨링 도구와 모델이 같은 규칙을 쓰게 했다.

구분	내용
사람 (수동)	포장에 찍힌 그대로 입력(FEB/26/21 , 30 12 23). 병기는 늦은 날짜, 제조일자만 있으면 NONE , 판독 불가 등 태그 9종
도구 (자동 규칙)	연도가 뒤면 일/월/년, 2자리 세 개는 년/월/일 우선, 공백 구분은 일/월/년, 영문 월, 연·월만 있으면 YYYY-MM-NONE
수행	5명이 블록 단위로 분담, 해상도별로 섞어 무작위 배정. 파이프라인은 실행 때마다 도구와 규칙이 같은지 자가검증

정답 라벨도 검증했다. 오답 446장을 사람이 전부 다시 봤다. 라벨 오류가 16장이었고 그중 11장은 모델이 맞고 사람이 틀린 것이었다. 8장은 숫자 한 글자를 잘못 옮긴 것이다. 점검자가 고친 18장 중 3장도 규칙과 어긋나 다시 바로잡았다. 사람이 옮겨 적은 날짜는 틀린다는 이 경험이 6절의 출발점이다.

2-3. 전처리 내용

긴 변 640px 로 줄여 읽고 후보가 없을 때만 1,024px 로 다시 읽는다(해상도를 올려도 $\pm 1\%$ p 에 시간만 30~50% 늘고, 480px 로 내리면 53.4 → 6.4% 로 무너진다. 초기 구성 실험). 허용 문자 밖의 글자는 지우지 않고 공백으로 바꾼다(지우면 2021(3) 이 20213 으로 붙는다). 후보가 없는 사진에만 도트 인쇄용 침식·블러를 건다(500장 +17/-0). 9자리 이상 이어진 숫자는 해석 전에 지운다(품목보고번호 앞 8자리가 날짜로 읽힌다).

3. 아키텍처 설계 논리

3-1. 전체 파이프라인 아키텍처 구조도




그림 1. 전체 파이프라인 구조도

- ① 1차 읽기 (640px) · 글자 위치 탐지 → 큰 글자부터 인식. 완전한 날짜를 찾으면 잔글씨 생략
 - 후보 없음 → 1,024px 재시도 → 도트 인쇄 전처리 후 재시도
- ② [본선] 주변 재탐지 · 후보 줄 옆에 크기 비슷한 숫자 줄이 있을 때만. 찾은 줄은 후보에 보탬
- ③ 다시 읽기 · 후보 줄만 원본 해상도로 재인식 → 1차 결과와 다수결
 - [본선] 1차 후보를 지우지 못하게 함 · 글자 상자 넓히기 · 깨진 줄 다시 읽기
- ④ 못 읽은 사진 전용 · 파인튜닝 인식기 → [본선] 작은 사진은 2배 확대
- ⑤ 해석·선택 · 형식 정규화 → 신뢰 등급 → 연도 범위 → 가장 낮은 날짜
- 시간 예산 가드 · 예상 소요가 예산을 넘으면 단계를 줄임
- 출력 · YYYY-MM-DD / YYYY-MM-NONE / NONE-MM-DD / NONE

모델은 탐지기 1개와 인식기 2개, 합쳐 약 21MB 다. 나머지는 규칙이다. 비용이 큰 재시도는 모두 조건부라 사진의 88% 는 재시도 없이 끝난다.

3-2. 모듈별 설계 의도 및 기술 선택 이유

풀려는 문제	선택	버린 대안과 근거
4코어 CPU 의 시간 한도	PP-OCRV5 mobile	EasyOCR 탐지기를 쓰면 장당 5.8초로 한도 초과. 교체 후 1.8초, 정확도 39.1 → 67.7% (초기 라벨 133장)
해상도를 올리면 시간이 는다	640px, 후보가 없을 때만 1,024px	전체 해상도 상향 5개 구성이 모두 $\pm 1\%$ p, 시간 +30~50%
1차 읽기의 한 글자 오독	후보 줄만 다시 읽어 다수결	다시 읽은 값으로 덮어쓰기. 덮어쓴 답의 정답률 61.7%, 1차 값을 유지한 답 72.3% (초기 구성)
두 줄이 한 상자로 잡힌 병기	조건을 만족하는 사진만 재탐지	모든 사진에 걸면 장당 6.2초. 조건부로 병기 +5/-1
도트 인쇄를 못 읽음	못 읽은 사진에만 파인튜닝 인식기	1순위로 쓰면 +38/-27, 다시 읽기에 쓰면 +86/-64. 못 읽은 사진에만 쓰면 +7/-0
서버 속도를 모름	시간 예산 가드 3단계	시간 초과는 결과 파일이 없어 정확도까지 0점
틀린 날짜를 자신 있게 냄	후보가 없으면 미인식	자주 나오는 날짜 찍기. 미인식은 손 입력으로 이어지지만 틀린 날짜는 잘못된 정보로 남는다

3-3. 후처리 규칙 설계

(1) 소비기한과 다른 숫자의 구분

헛갈리는 숫자	구분 방법	확인
품목보고번호·바코드·제조번호	9자리 이상 숫자열 제거	시험 6종 모두 날짜로 읽히지 않음
전화번호	날짜 형식(자릿수·구분자·연도 범위)에 맞지 않음	시험 10종 중 9종. 남은 1종은 낮은 등급 후보라 완전한 날짜에 밀림
영양성분 숫자, 시각, 생산 라인 기호	신뢰 등급: 완전한 날짜가 있으면 약한 패턴은 보지 않음	500장 +15장. 시험 8종 통과
제조일자	같은 등급 안에서 가장 낮은 날짜	병기 78.3%
두 날짜에 걸친 가짜 날짜	[본선] 구분자가 섞인 쪽을 버림	+10/-0
먼 미래 연도	연도 2017 ~ 2031 만 허용	

(2) 날짜 정규화

표기	해석
4자리 연도가 앞 / 뒤	연월일 / 일월연
2자리 세 개 (26.03.20)	년/월/일 우선. 불가능하거나 연도가 2028 이상이면 일/월/년
BBD EXP 가 함께 있음, 공백 구분	일/월/년
영문 월 (22OCT2021), 미국식	월 위치 확정. 미국식은 일/월/년이 불가능할 때만
연·월만 / 월·일만	YYYY-MM-NONE / NONE-MM-DD
[본선] 콜론 구분, 날짜 뒤 숫자, 연·월 사이 구분자 빠짐	+6/-0, +16/-1, +8/-1

(3) 미인식 기준: 후보가 0개면 NONE . 연도나 일만 없으면 그 칸만 NONE . 자주 나오는 날짜를 찍지 않는다.

4. 모델 선택 근거 및 성능 평가

4-1. 비교한 모델·대안과 최종 선택 근거

비교 대상	결과	판단
EasyOCR 탐지 + 인식	39.1%, 장당 약 5초	속도 초과
PP-OCrv5 mobile 탐지 + 인식	67.7%, 1.8초	채택 (인식기 v3·v4·v5 중 v5)
합성 도트 글자 3,000장 추가 학습	정밀도 84 → 81%	기각
인식기 셋 다수결	+8/-4, 장당 +0.43초	기각
한국어 인식기로 한 번 더 읽기	판정용 +7/-2, 장당 +0.3~0.7초	기본 꿈 (시간 여유를 택함)

위 표 첫 두 줄의 정확도는 초기 라벨 133장 기준이고, 합성 도트 학습의 정밀도는 봉인 500장 기준이다.

4-2. 날짜 추출 정확도 결과

검증 방법: 정답은 팀이 직접 라벨링한 3,352장이고 연·월·일이 모두 같아야 정답이다. 500장은 봉인하고 채택 판정은 나머지 2,852장에서만 했다. 새로 맞힌 장과 새로 틀린 장을 따로 세어 **퇴보가 회복의 1/3 을 넘으면**

기각했다. 임계값을 데이터에 맞추지 않고 구조 규칙만 채택했다.

측정	완전일치	필드평균	그 외
봉인 500장	86.2%	90.8%	미인식 3.0%, 답한 것의 정밀도 88.9%
└ 해상도별	저 83.7 · 중 89.5 · 고 86.7%		병기 51장 78.4%
판정용 2,852장	86.7%		병기 78.3% · 비병기 87.7%

튜닝에 쓴 사진(86.7%)과 쓰지 않은 사진(86.2%)의 수치가 비슷하다. 직접 찍은 폰 사진 389장은 어려운 유형을 골라 찍은 것이라 실제 판매자 사진의 평균은 아니다. 다만 6절의 서비스가 받는 입력과 가장 가까워, **6절의 운영 수치는 이 389장으로 계산했다**(미인식과 오답의 방향은 4-3, 자동 입력 비율은 6-2).

단계별 효과(판정용): 예선 구성 82.3% → 다시 읽기 규칙 84.3%(+63/-5) → 한국어 인식기 2차 의견 84.7% (+14/-1) → 해석 규칙 4개 86.0%(+39/-2) → 주변 재탐지·확대 재시도·파인튜닝 재시도 86.9%(+25/-1) → 시간 여유를 위해 한국어 인식기를 끈 최종 구성 86.7%.

4-3. 오류 사례 분석 및 개선 과정

오답을 '정답이 어느 단계에서 사라졌는가'로 진단했다. (예선 구성, 3,352장 중 오답 603장. 단계별 개수는 전체에서 켜고, 규칙 도출과 채택 판정은 봉인 500장을 뺀 2,852장에서 했다)

단계	장수	본선 처방	결과
선택 실패: 후보에 정답이 있는데 다른 것을 고름	19	구분자 일치 규칙	+10/-0
다시 읽기가 맞던 답을 덮어씀	111	1차 후보를 지우지 못하게 함	+53/-5
오독: 숫자를 잘못 읽음	290	글자 상자 넓히기, 해석 규칙, 깨진 줄 다시 읽기	+36/-2
미검출: 후보가 없음	183	주변 재탐지, 작은 사진 확대, 파인튜닝 재시도	+25/-1

오답의 방향. 서비스에서는 어느 쪽으로 틀렸는지가 중요하다. 늦게 읽으면 남은 날이 실제보다 많게 표시된다.

오답 유형	서비스에서 일어나는 일	봉인 500장	폰 사진 389장
미인식	빈칸. 손으로 입력	3.0%	21.9%
이르게 읽음	남은 날이 적게 표시	5.3%	15.8%
늦게 읽음	남은 날이 많게 표시. 위험한 쪽	3.2%	4.9%

이르게·늦게 읽은 비율은 라벨이 완전한 날짜인 사진(474장, 368장) 기준이다. 이르게 읽은 값의 중앙값은 약 1년으로, 병기 제품에서 제조일을 읽은 경우다.

기각한 실험	결과	배운 것
파인튜닝 인식기를 다시 읽기에	+86/-64	점수가 올라도 맞던 답을 흔들면 버린다
깨진 줄 다시 읽기 (하나라도 읽히면 추가)	+10/-2	둘 이상 일치로 바꿔 +6/-0
어두운 사진 밝기 보정	퇴보가 더 많음	촬영 단계에서 막아야 한다

규칙으로 닿는 오답은 거의 다 썼다. 남은 것은 인식 품질(도트·각인)과 저해상도다.

5. 속도·비용 검증

5-1. CPU 추론 속도 측정

개발 PC 두 대에서 연산 스레드를 4개로 제한해 잤다. 코어를 묶지는 않았고, 느린 쪽 값을 기준으로 본다. 2.7초는 단계별 측정(3.0초)에서 한국어 단계를 뺀 환산값이다.

구성	장당	500장	한도 대비
EasyOCR 탐지기를 쓴 구성	5.8초	2,905초	초과
예선 제출본	3.2초	1,595초	64%
본선 최종 구성 (개발 PC 1 / 2)	2.7초 / 4.0초	1,370 / 1,985초	55% / 79%
한국어 인식을 켜면 (개발 PC 2)	4.7초	2,350초	94% → 끄

사진의 88% 는 장당 1.8초에 끝나고 재시도까지 간 12% 가 시간의 절반을 쓴다. 단계별로는 1차 읽기 40%, 도트 전체리 재시도 23%, 파인튜닝 재시도 11% 순이다(한국어 단계를 켜 측정).

5-2. 속도 및 오탐 최적화 전략

전략	효과
경량 모델로 교체	5.8 → 1.8초
완전한 날짜를 찾으면 잔글씨 생략	영양성분표 인식 생략
탐지는 한 번, 다시 읽기는 잘라낸 조각만	탐지가 비용의 대부분
재시도는 못 읽은 사진에만	평균 약 +1초
시간 예산 가드	최근 20장 속도로 총 소요를 예측해 단계를 줄임

시간 예산 가드는 실제로 두 번 발동했다. 폰 사진 389장을 돌리던 중 PC 가 절전에 들어가 한 장이 2.8시간으로 잡혔고, 가드가 재시도를 생략해 결과 파일 389행을 끝까지 만들었다. 같은 222장에서 재시도를 생략하면 101장, 하지 않으면 130장을 맞혔다. 10/2 새 가상환경 재현에서도 발동했다. 앞 86장이 느려 총 소요를 2,046초로 예측해 경량 1단계로 내려갔고, 봉인 500장은 1,340초에 81.4% 로 끝났다(가드를 끄면 1,599초에 86.2%). 발동 전 86장의 답은 공식 결과와 같았다. 오탐은 신뢰 등급·긴 숫자열 제거·연도 범위로 억제한다(답한 것의 정밀도 88.9%).

5-3. 학습 자원 사용 내역

인식기 파인튜닝(393장, 30 epoch)은 무료 Colab T4 에서 약 1.5시간 걸렸다. 기각한 학습 두 번도 같은 환경이다. 추론과 측정은 개발 PC CPU 로 했다. **유료 GPU 와 클라우드 는 쓰지 않았고 비용은 0원이다.**

6. 도메인 활용 및 운영 기획

6-1. 적용 도메인 및 도입 대상 기업/산업 정의

중고거래 플랫폼의 식품·건강기능식품 게시글.

항목	내용
문제	소비기한은 판매자가 손으로 적고, 구매자는 확인할 방법이 없다. 약사 단체 모니터링에서 적발된 위반 375건 중 가장 많은 유형이 '사용기한 확인 불가·불일치'(211건)였다 (보도, 매체 간 내역 차이 있음). 중고거래의 식료품·기호품 소비자 상담은 2022년 19건에서 2025년 661건으로 늘었다 (한국소비자원 자료, 보도)
규모	건강기능식품 개인 간 거래 게시글 482,675건, 위반 조치 14,729건(3.05%), 그중 소비기한 미준수 725건 (2024-05 ~ 2025-12, 식약처 자료). 명절에는 위반이 평시의 3배 이상으로 늘었다 (보도)
시의성	2026년 추석 연휴의 선물세트 거래량이 작년 연휴보다 50% 늘었다 (플랫폼 집계, 보도). 선물세트는 날짜가 인쇄된 미개봉 가공식품·건강기능식품이다
지금의 처리	게시 뒤에 모니터링과 신고로 삭제. 당근마켓의 전담 모니터링 인력은 5명으로 보도됐다. 플랫폼이 사진을 OCR 로 읽는다는 보도는 건강기능식품 문구·인증마크 확인 용도였고, 소비기한을 읽는다는 자료는 찾지 못했다
받아들일 바탕	플랫폼은 사진을 올리면 상품명·카테고리·상태를 자동으로 써 주는 기능을 운영한다(2025-05). 식약처는 포장을 찍으면 소비기한 등을 읽어 주는 장애인용 서비스를 냈다(2026-09). 포장 판독과 사진 기반 자동 입력은 각각 있고, 둘을 게시 흐름에서 잇는 자리가 비어 있다
선례	일본 메루카리는 소비기한 인쇄 부분의 사진을 필수로 요구하고, 도착 후 1주 안에 기한이 끝나는 식품의 출품을 금지한다. 자동으로 읽는다는 자료는 찾지 못했다
1차 대상	위반 통계가 공개된 건강기능식품 카테고리. 거래 조건은 미개봉, 소비기한 이내, 연 10회 이하
하지 않는 것	사기 방지, 개봉 여부 판별. 스티커를 붙이거나 다른 상품을 찍으면 막지 못한다

이 시스템은 속이려는 소수를 잡는 장치라 아니다. 날짜를 확인하지 않고 올리는 다수를 게시 전에 돕고, 속이려는 소수는 기존 사후 모니터링이 맡는다.

모델 결과	판매자에게 일어나는 일	남는 위험
맞게 읽음	채워진 날짜를 확인	없음
미인식, 확신도가 낮음	빈칸. 손으로 입력	지금과 같음
이르게 읽음	날짜 확대본을 보고 고침	안 고치면 판매자에게 불리
늦게 읽음	날짜 확대본을 보고 고침	안 고치면 남은 날이 많게 표시

판매자가 마지막에 확인하므로 모델의 실수는 대부분 수정 한 번으로 끝난다. 모델을 사람의 판독 정확도와 비교하지 않는다.

6-2. 운영 아키텍처 설계 (서버 / 온디바이스)

플랫폼 서버에서 추론한다. 모델 21MB, CPU 전용이다. 폰 안에서 도는 방식은 해 보지 않아 다음 단계로 둔다.

날짜면 촬영 (해상도·흐림 검사) → 서버 판독 (10초 제한)
→ 확신도가 기준 이상이고 완전한 날짜면 소비기한 칸 자동 입력, 아니면 빈칸
→ 판매자가 날짜 확대본을 보며 확인 또는 수정
→ 게시글에 "판매자 사진에서 읽은 날짜 · 남은 일수 · 날짜면 원본" 표시
기록: 원본 사진, 촬영 시각, 판독값, 확신도, 판매자 수정 이력, 모델 버전

자동 입력 기준 (폰 사진 389장)	채워지는 비율	채운 값의 정확도	틀린 값을 받는 판매자
기준 없음	70.2%	70.3%	20.8%
확신도 0.7 이상	44.7%	77.0%	10.3%
확신도 0.9 이상	16.5%	87.5%	2.1%

설계	이유 (측정값)
확신도 기준은 0.7	기준 없음 → 0.7 은 틀린 값 41장을 피하러 맞는 값 58장을 포기(1.4 대 1), 0.7 → 0.9 는 32장을 피하러 78장을 포기(2.4 대 1). 틀린 값 하나의 비용이 맞는 값 하나의 이득의 1.4 ~ 2.4배일 때 0.7 이 맞다
확신이 낮은 판독값은 보여 주지 않고, 판매자 입력과 대조	채워 준 값을 같은 사람이 확인하는 것만으로는 검증이 아니다. 판매자가 먼저 입력한 값이 판독값과 다르면 확대본을 보여 준다
날짜 확대본, 최대 기한 검사	확신도만으로는 위험한 오류가 걸러지지 않는다. 늦게 읽은 18장 중 13장이 확신도 0.7 이상. 최대 기한 검사는 크게 늦은 값만 막는 보조 장치이고 효과는 재지 못했다
10초 안에 답이 없으면 빈칸	폰 사진의 32% 가 10초를 넘겼고 그 123장 중 맞힌 것은 13장. 제한을 걸면 자동 입력 44.7 → 40.6%, 틀린 값 10.3 → 8.2%
판독값만으로 자동 차단하지 않음	기한이 남은 글의 11.2% 가 지난 것으로 읽힌다 [가정] . 판정은 판매자가 확인한 날짜로
판매자가 값을 고치면 한 번 더 확인	판독값과 입력값을 둘 다 기록. 수정의 대부분은 오독을 바로잡은 것이라 제재하지 않음
'확인됨' 대신 판독값과 원본 표시	보증 표시는 조작된 날짜에 신뢰를 빌려준다
선물세트는 상품별로 촬영	세트는 가장 이른 날짜가 중요한데 우리 규칙은 한 사진에서 가장 늦은 날짜를 고른다
판매자 수정값을 검수 후 학습에 사용	사람이 입력한 값도 틀린다 (2-2절). 수정값에는 글자 위치가 없어 학습용 글자 조각을 따로 확보해야 한다

6-3. 예상 운영 비용 산출

건강기능식품 카테고리 기준. 게시글은 월 약 2.4만 건, 하루 약 800건이다.

항목	계산	값
하루 연산 시간	800장 × 4.0초 ~ 10.8초(폰 사진 평균. 10초 제한을 걸면 5.2초)	53분 ~ 2.4시간. 서버 1대의 4 ~ 10%
서버 비용	4 vCPU·8GB 시간당 196~200원 (네이버클라우드 High CPU-g2 200원, KT Cloud 동일 사양 193~214원과 일치)	전용 1대 연 약 169만 원(부가세 별도). 기존 서버의 여유분이면 연 7만 ~ 17만 원
게시글 한 건당	연 비용 ÷ 연 약 29만 건	0.2 ~ 5.8원
라이선스·GPU·학습비	공개 모델, 무료 학습	0원
사람 검토	이의 제기 건만	발생률 미측정

개발, 앱 화면 변경, 운영 인력은 포함하지 않았다.

6-4. 비즈니스 손실 절감 효과 및 ROI 기획

편익을 OCR 이 있어야 되는 것과 아닌 것으로 나눴다.

가치	OCR 이 있어야 하나	근거
입력값과 사진의 대조	예	판매자가 손으로 넣거나 고친 값이 틀렸을 때, 그 값이 판독값과 우연히 같아 지나갈 확률은 봉인 500장 평균 0.2%, 폰 사진 0.4%. 틀리게 채워진 값을 판매자가 그대로 둔 경우는 이 대조로 잡지 못하고 날짜 확대본과 최대 기한 검사가 맞는다
날짜면이 찍혔는지 확인	예	메루카리는 이 확인을 사람이 한다
입력 편의, 라벨 축적	예	폰 사진의 41 ~ 45% 자동 입력 (10초 제한을 걸면 41%)
남은 일수 표시, 기한 지난 글 자동 숨김	아니오	날짜 칸만으로 가능. OCR 의 편익으로 세지 않았다

인력 절감으로는 가치를 설명하지 않는다. 금액으로 말할 수 있는 편익은 위반 게시글의 사후 처리비인데, 계산하면 본전이 되지 않는다.

조건	연간 소비기한 위반	게시 전에 걸러지는 비율	연간 서버 비용	손익분기 1건당 처리비
20개월 평균 (옛 6개월 조건 포함)	435건	50% [가정]	17만 원	약 780원
조건 완화 뒤 추정	약 180건	50% [가정]	17만 원	약 1,900원

사람이 30초에 검토하는 비용은 약 86원이다 [가정]. 손익분기 처리비는 이보다 9 ~ 22배 크다. 개발과 앱 화면 변경 비용, 판매자가 사진을 한 장 더 찍는 부담도 여기에 들어 있지 않다.

플랫폼이 도입할 이유는 비용 절감이 아니라 규제 대응이다. 건강기능식품 개인 간 거래는 시범사업이고, 국회에서 당근마켓의 전담 모니터링 인력이 5명에 불과하다는 지적이 나왔으며, 판매업 신고 없는 판매를 막는 개정안이 국회에 발의돼 있다. 게시글마다 날짜면 사진과 판독 기록이 남는 것은 관리 체계의 증거가 된다.

7. 한계와 보완 계획

한계	현재	보완
폰 사진	미인식 21.9%, 자동 입력 41 ~ 45%. 찍은 사람과 촬영 조건에 따라 크게 갈림	촬영 안내와 해상도 검사, 판매자 수정값으로 재학습
389장의 대표성	어려운 유형 위주로 찍음	실제 게시 사진으로 다시 측정
각인, 저해상도	각인은 대부분 못 읽음. 저해상도 83.7%	규칙으로는 끝났다. 인식기 학습 데이터가 필요
채점 서버 속도 미실측	개발 PC 기준 한도의 55 ~ 79%	시간 예산 가드로 완주 보장
봉인 500장	완전 무오염은 아님	예선 때 오답을 보고 라벨 7장을 고쳤다. 본선 판정은 전부 나머지 2,852장에서
조작, 개봉 여부, 카테고리를 바꿔 촬영을 피함	막지 못함	범위 밖으로 명시. 원본과 수정 이력 보존
판매자가 보지 않고 확인을 누름	미측정. 확신도 0.7 로 채운 값 가운데 늦게 읽은 값(폰 사진의 3.3%)이 그대로 게시되는 비율을 모른다	확인을 버튼이 아니라 일(日) 칸 재입력 같은 동작으로. 실제 수정 비율을 지표로
소비기한 위반은 적다	게시글의 약 0.15%	단속이 아니라 정보 제공을 목적으로 둠
제도가 바뀔 수 있음	시범사업, 종료 시한 미공개	기한 지난 식품은 플랫폼 규칙으로도 금지라 가공식품에 같은 설계 적용
근거 수치	보도와 공개 통계. 플랫폼 내부 자료 없음	가공식품 게시글 수는 공개 자료가 없음

다른 현장과의 연결: 빠대는 '읽은 값을 기준값과 대조하고 예외만 사람에게 넘긴다'이다. 출하 표시물 검증에서는 기준값이 품목 마스터, 여기서는 판매자 입력이다. 기록 항목(원본·판독값·수정 이력·모델 버전)은 감사 추적적이고, 4-2의 채택 기준과 봉인 500장은 모델을 바꿀 때의 재검증 기준이다.

확장: 건강기능식품 → 가공식품·명절 선물세트 → 지금은 지우는 품목보고번호를 읽어 회수 대상 확인. 같은 파이프라인은 식품공장의 출하 전 날짜 인쇄 확인에도 쓸 수 있다. 공장은 정답(제조일 + 품목별 소비기한 일수)을 알아 대조만 하면 되고, 기대값을 어긋나게 넣은 실험에서 오인쇄를 놓칠 확률은 한 장당 평균 0.2% 였다.

8. 추가 참고 자료 (선택)

- 저장소: <https://github.com/LEEbyeongchul/itda3-CODE-subway>
- 실험 기록 `docs/실험_기록.md`, 날짜 해석 규칙 `docs/날짜_해석_규칙.md`, 도메인 출처 `docs/D안_근거자료.md`
- 새 가상환경 재현 로그: `제출/재현_2026-10-02/` (봉인 500장이 공식 결과와 모두 일치, 최대 메모리 2.0GB, 한도 8GB)
- 재현 명령: `pip install -r requirements.txt` → `bash download_weights.sh` → `jupyter nbconvert --to notebook --execute predict.ipynb`